2022级生产实习讲座 • 2025-7-9

面向数据赋能的新一代数据库技术

于 戈

数据与知识工程团队

辽宁省数字化装备综合信息处理重点实验室

计算机科学系

提纲

01 研究背景

02 研究目标

03 关键技术

04 总结展望

05 团队介绍

提纲

01 研究背景

02 研究目标

03 关键技术

04 总结展望

05 团队介绍

研究背景：数字化时代

数字化时代是继工业时代和信息时代（电脑时代）之后的一个新时代,也称作后信息时代（post-information age）。“人类生存于一个虚拟的、数字化的生存活动空间，在这个空间里人们应用数字技术（信息技术）从事信息传播、交流、学习、工作等活动，这便是数字化生存。”

尼古拉斯· 尼葛洛庞帝 --美国MIT计算机教授、未来学家

互联网 → 云计算 → 大数据 → 人工智能

1995年	2007年	2012年	2016年
因特网； 全球计算机； 信息高速公路； 互联互通	计算能力是一种服务； 软件即服务、平台即服务、 架构即服务	数据是能量； 数据是资产； 数据是生产要素； 数据驱动一切	智能是生产力； 知识创造财富； 人+(知识+工具)
电子邮件； 万维网、社交网络、社交媒体、移动互联网、物联网、元宇宙；QQ、微信、抖音	云计算、边缘计算； IBM云计算平台、Amazon云服务、天河超算、 阿里云、华为云； 淘宝、京东、支付宝	数据科学、数据驾驶舱、NoSQL数据库、数据湖、区块链； Hadoop，Spark； OceanBase、TiDB以太坊、Fabric	AlphaGo、深度学习、大模型、图像识别、无人驾驶、机器翻译、智慧医疗..； Tensorflow、ChatGPT DeepSeek

研究背景：数字化转型

“放眼世界，我们面对的是百年未有之大变局”
--- 习近平总书记（2017年）

- 数字化转型
  - 以数字技术为核心驱动力，对组织的业务模式、运营流程、组织架构、文化理念进行系统性重塑，从而实现价值创造方式的根本性变革
- 举例：数字经济
  - 经济：人们进行商品生产、流通、分配、消费等一切活动的总称，是价值的创造、转化与实现
  - 数字经济：数字技术在整个经济环境和经济活动中广泛使用的经济系统。也称为：互联网经济、信息经济、智慧经济
  - 产业数字化：数字化的技术、产品与服务向传统产业进行多方向、多层面、多链条的加速渗透。例如：新零售、新制造
  - 数字产业化：数字产业链和数字产业集群。例如：5G网络、数据中心、工业互联网

研究背景：数据是新范式、新动力、新要素

发挥数据要素的放大、叠加、倍增作用，构建以数据为关键要素的数字经济，是推动高质量发展的必然要求。为深入贯彻党的二十大和中央经济工作会议精神，落实《中共中央 国务院关于构建数据基础制度更好发挥数据要素作用的意见》，充分发挥数据要素乘数效应，赋能经济社会发展，特制定本行动计划。

——“数据要素×”三年行动计划（2024—2026年）”

数据是新动力

蒸汽动力（Steam Power）

电气动力（Electric Power）

数据动力（Data Power）

数据是新范式

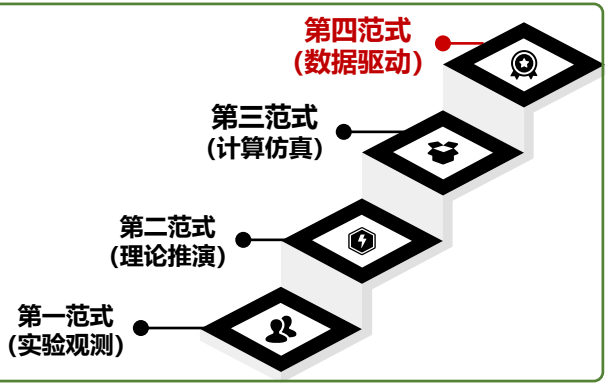

数据是第五生产要素

农业时代

生产要素：土地、劳动
代表人物/事件：威廉•配第，庞巴维克

第一次工业革命

生产要素：土地、劳动、资本
代表人物/事件：亚当•斯密，萨伊，约翰•穆勒

第二次工业革命

生产要素：土地、劳动、资本、企业家才能
代表人物/事件：马歇尔

数字时代

生产要素：土地、劳动、资本、企业家才能、数据
代表人物/事件：十九届四中全会，《关于构建更加完善的要素市场化配置体制机制的意见》

研究背景：数据库发展历程

历史

数据库技术应数据管理任务的需要而产生：如何对数据进行**分类、组织、编码、存储、检索和维护**。

史前

COBOL (Common Business Oriented Language)

开端

CODASYL （Conference on Data System Language ）& DBTG 报告 （数据库领域第一个图灵奖得主 Charles Bachman）

巅峰

IBM DB2 ORACLE

关系模型 E.F.Codd （图灵奖）& 事务处理 Jim Gray （图灵奖），成熟的关系型数据库涌现。

哲学

抽象

- 排除和抽出，实质是**概括**，找出**共性**、**本质**的东西。
- 抽象成就了数据库理论和产业。

关系数据模型是对数据语义的抽象

Relational Model for Data Semantics

事务处理模型是对应用逻辑的抽象

Transaction Model for Business Logic

数据库基准评测是对产品能力的抽象

Benchmarks for System Capacity

让数据好用

- 把数据技术**装备化，大众化**便于普通用户使用数据。

把数据用好

- 整合各类型数据信息，充分释放数据蕴含的**价值**。

研究动机

多模态数据依赖多系统，数据使用高门槛

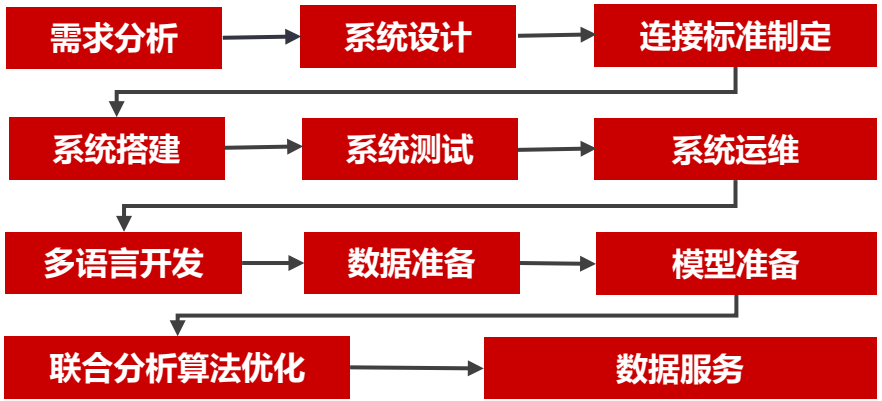

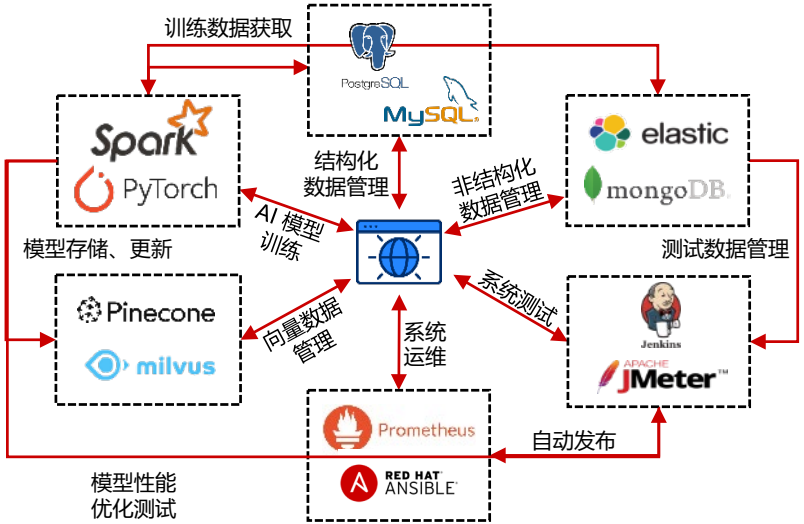

运维成本高企

需要对不同的系统**分别进行维护。**

开发门槛陡峭

使用不同系统的开发方式有**差异性**，大幅增加了**开发难度**。

任务复杂繁重

任务执行流程长，涉及跨系统的数据搬运，**开销大、稳定性低**。

硬件潜力释放不足

缺乏对异构硬件资源的**协同优化**，无法充分发挥**硬件性能**。

提纲

01	02	03	04	05
研究背景	研究目标	关键技术	总结展望	团队介绍

研究目标

面向多模态数据灵活、高效管理的一体化数据库

- 以**统一数据模型**纳管**多源、异构数据**
  - 结构化数据、半结构化数据、非结构化数据
  - 原始数据、机器学习模型、中间结果、衍生数据
  - 涵盖关系运算、张量运算的**完备算子**
- **柔性解耦**与**弹性扩展**的云原生架构
  - **异构硬件**资源的协同优化
  - 可扩展、高可用的**分布式**计算框架
  - 基于管理组件**解耦**的高效资源分配架构
- **跨模态、跨引擎、跨域**的数据联合查询与分析优化
  - 面向跨模态数据的**查询优化**
  - 基于混合计算引擎的**执行优化**
  - **跨空间域、管辖域、信任域**的数据管理

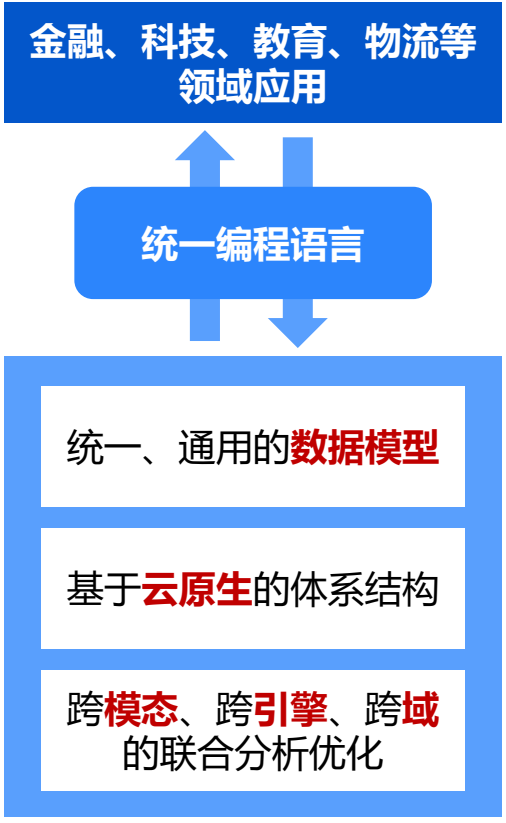

基本构想

应用程序

系统搭建

- milvus — 向量数据管理
- PostgreSQL / MySQL — 结构化数据管理
- elastic / mongoDB — 非结构化数据管理
- Spark / PyTorch — AI 模型训练
- Pinecone

系统测试、运维、部署

Jenkins, APACHE JMeter, ANSIBLE, Prometheus

大幅简化

应用程序

统一编程语言

新一代一体化数据库系统

存储　计算

需求分析 → 数据抽象 → 模型构建 → 数据服务

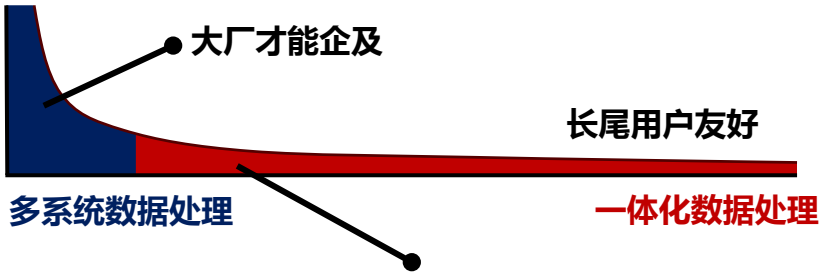

数据大众化、开发大众化、AI 大众化！

具体目标1：统一、通用的新一代数据库模型

设计通用数据模型，实现面向多源、异构数据的统一描述、组织和操作

大一统的数据描述与组织 → 完备的关系运算和张量运算逻辑算子 → 简洁易用的编程接口

统一组织形态

非结构化、半结构化、结构化数据

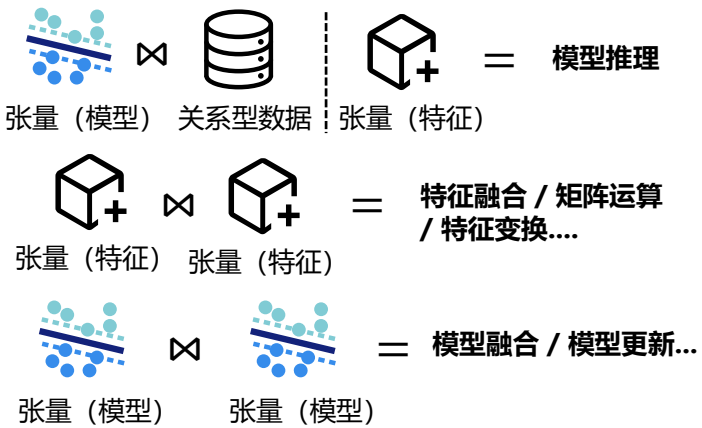


```
SELECT    name,
          location,
          dist(globalfeature, invoke
model image2vectormodels(url=
 "aidb.model/283939873") @X_Value =
 "aidb.image/949574603") AS score
FROM      landmarks
WHERE     score < 0.5
ORDER BY score DESC limit 1
```

难点：不同的数据形态之间的自转换以及复杂算子支持

具体目标2：新一代数据库系统的体系结构

研究可扩展、高可用、异构计算感知的新一代数据库系统体系结构

异构硬件协同的单节点处理架构 → **可扩展、高可用的分布式并行处理框架** → **弹性的云原生解耦架构**

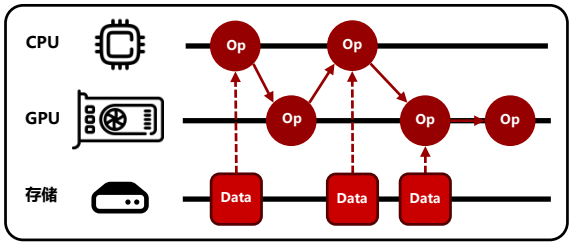

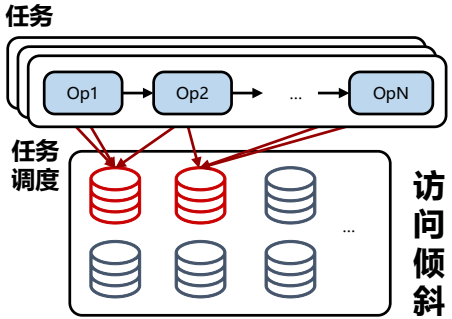

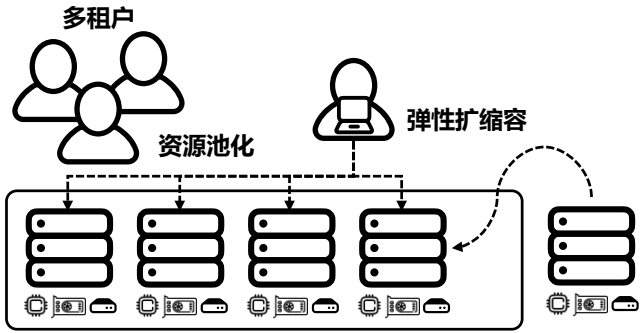

难点：异构资源的弹性分配、计算任务的高效划分调度、复杂任务的局部容灾

具体目标3：新一代数据库系统的查询优化技术

实现跨模态、跨引擎、跨域的联合分析查询环境下的性能自动优化

跨模态数据查询优化

用户对音乐的评论进行情感分析，并筛选评论正向的音乐

```
SELECT    Music.Category, SUM(Music.VisitCount)
FROM      Music JOIN Comments ON music_id
WHERE (INVOKE MODEL
SentimentModel(URL='ai.model/0x1234')
@X_Value=Comments.text) > 0.8
GROUP BY Music.Category;
```

代价模型

查询重写

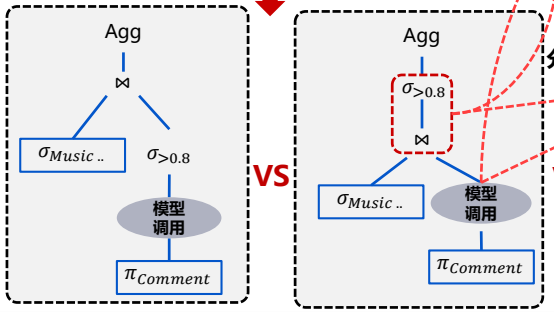

VS...

跨引擎执行与加速

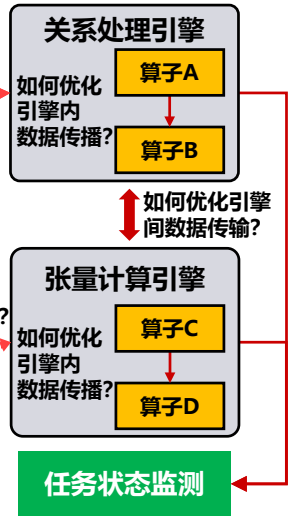

如何为算子分配计算引擎?

如何进行任务监测以改善运行时加速方法?

跨域数据管理

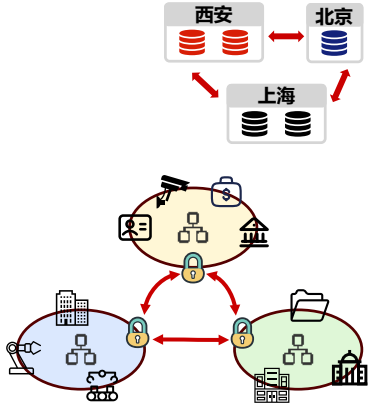

跨空间域管理中存在时延的不确定性

跨管辖域管理中存在语义的异构性

跨信任域管理中存在安全和隐私保护挑战

难点：面向多源异构数据、复杂分析任务的查询优化和执行优化

提纲

01	02	03	04	05
研究背景	研究目标	关键技术	总结展望	团队介绍

关键技术

新一代数据库和数据赋能技术

数据模型

挑战：支持多源异构数据的统一数据模型

数据、模型和过程的统一组织形态

面向多样化操作的复杂算子系统

易用、可扩展的数据访问语言

体系结构

挑战：异构计算感知、灵活的数据库体系结构

异构硬件协同的并行流水线处理架构

分布式任务调度与容错机制

服务-计算-存储解耦的云原生架构

核心技术

挑战：新型数据库的查询优化和跨域数据管理

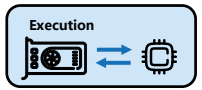

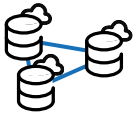

面向异构数据联合分析的查询优化

跨引擎混合查询执行框架

跨域数据管理技术

关键问题一： 什么样的数据模型能够统一表示异构数据及其复杂算子？

关键问题二： 面对海量异构数据以其复杂数据操作，如何构建灵活、弹性的系统体系结构？

关键问题三： 如何在跨域、跨引擎、跨模态的联合数据分析查询环境下自动优化处理性能？

关键技术1：统一、通用的新一代数据库模型

数据、模型和过程的统一组织形态

- 自适应轻/重量模型的表示与存储
- 多模态数据的统一描述
- 复杂过程的一致性描述

面向多样化操作的复杂算子系统

- 关系、张量之间完备的五大类算子
- 用于二次开发的定制逻辑算子组件
- 自适应算子识别与资源绑定

易用、可扩展的数据访问语言

- 数据、模型的通用声明式编程语言
- 复杂推理任务的封装机制
- 可扩展、可注册的用户自定义函数

深度学习模型的组织形态示例

元模型表

Model	LayerIn	LayerOut	WeightTable	Expression
model_1	0	1	...	...
model_1	1	2	[model_1_weight_1, model_1_bias_1]	$Wx+b$
model_1	2	3		
...	...	...	...	...

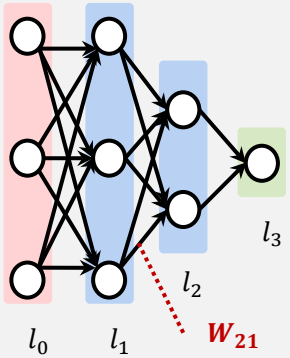

偏置表

NodeOut	Bias
0	b_0
1	b_1

权重表

NodeIn	NodeOut	Weight
0	0	w_{00}
0	1	w_{01}
1	0	w_{10}
1	1	w_{11}
2	0	w_{20}
2	1	w_{21}

张量 × 关系型复杂逻辑算子

张量与关系逻辑算子	推理/变换
张量与张量逻辑算子	融合
关系与关系逻辑算子	关联
单张量逻辑算子	特征抽取
单关系逻辑算子	增删改查

易用 SQL 任务示例

```
SELECT   user_info.uid,
         music_info.music_name
FROM     user_info
INNER JOIN
         AnalyzeMusicStyle(music)
AS music_info
ON music_info.style
IN user_info.favourite_styles
WHERE
         music_info.rank < 100;
```

推荐用户喜爱的音乐

关键技术2：新一代数据库系统的体系结构

异构硬件协同的并行流水线处理架构

- 跨硬件支持的混合计算任务统一表示
- 面向多样化任务流的并行处理策略
- 异构计算绑定的任务流水线机制

分布式任务调度与容错机制

- 高通量任务的分解与划分机制
- 负载感知的跨节点动态调度
- 局部容错检查点机制与故障恢复策略

服务-计算-存储解耦的云原生架构

- 资源高效的解耦合三层架构
- 数据访问模式敏感的存储布局方案
- 高可用、高弹性的云原生架构

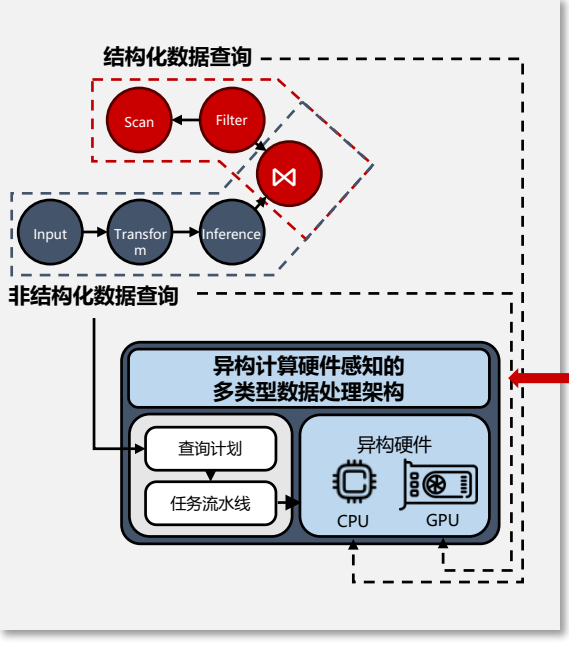

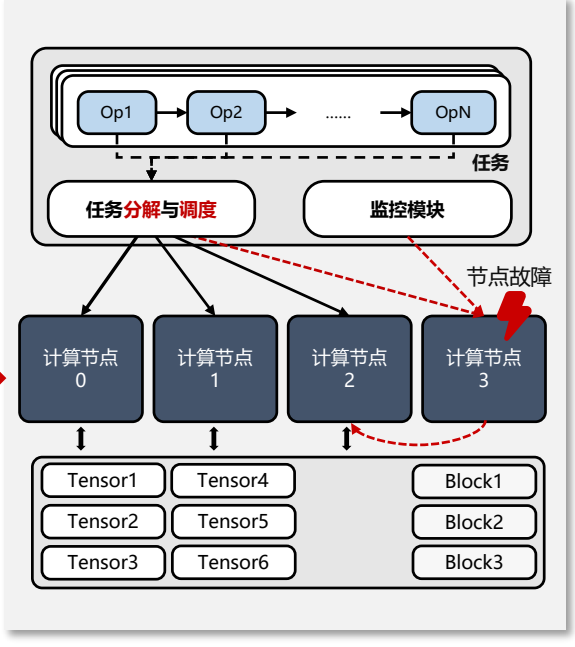

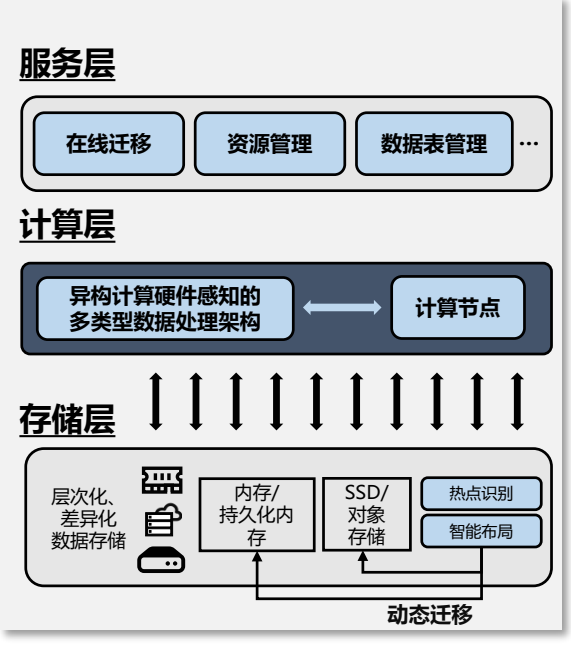

关键技术3：新一代数据库系统的查询优化技术

面向异构数据联合分析的查询优化

- 面向异构数据算子的统一代价模型
- 公共子计划的标记与优化策略
- 基于物化视图的计算结果重用机制

跨引擎混合查询执行框架

- 关系型和非关系型算子的等价转换
- 面向关系运算和张量计算的运行时加速
- 基于虚拟快照机制监控的任务优化

跨域数据管理技术

- 跨空间域的事务处理和数据传输
- 跨管辖域的数据融合
- 针对跨信任域下“数据孤岛”问题的同态压缩和加密

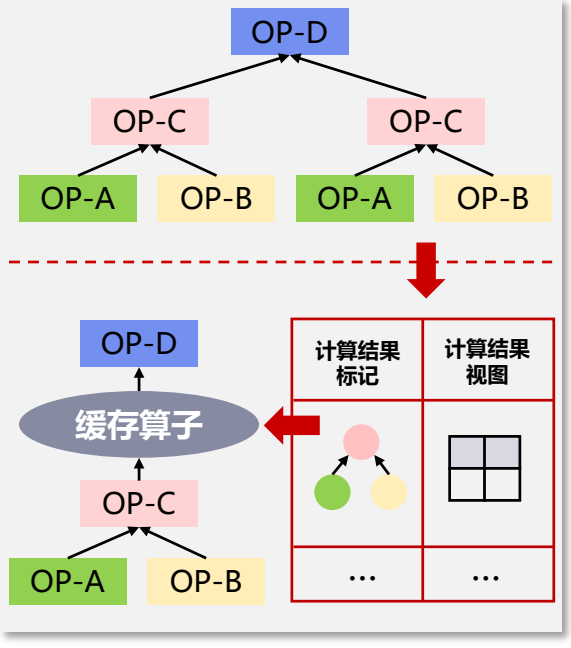

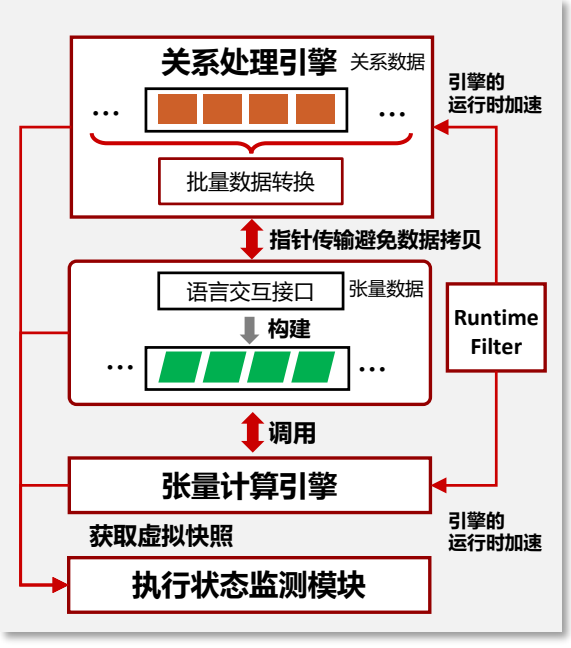

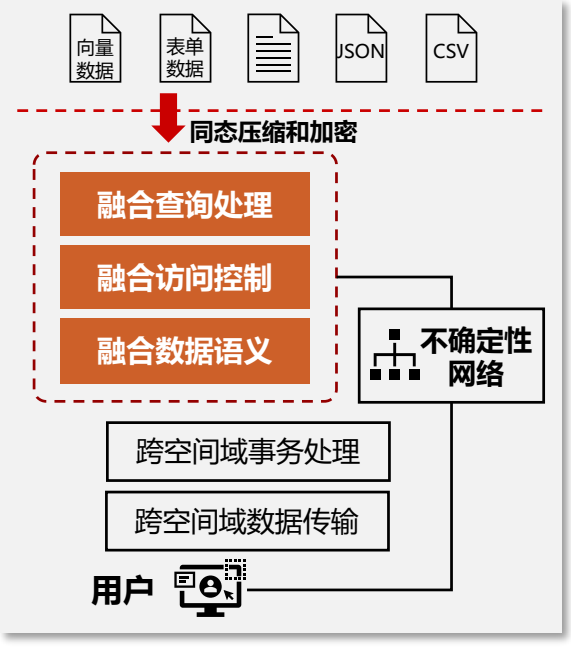

原型系统实现

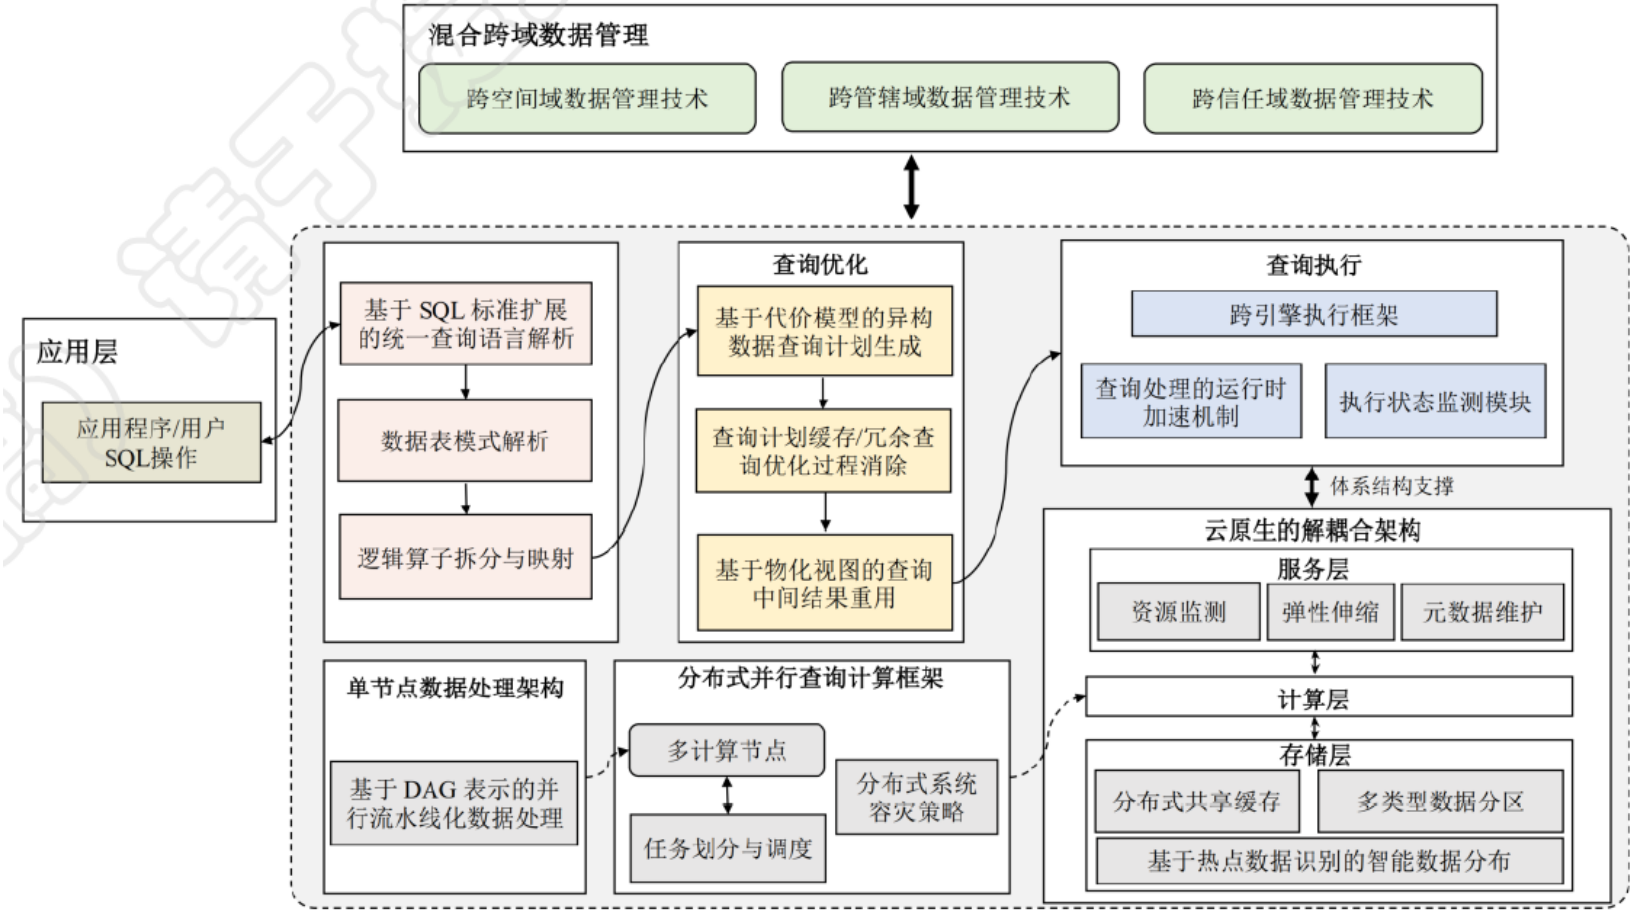
混合跨域数据管理
跨空间域数据管理技术
跨管辖域数据管理技术
跨信任域数据管理技术
应用层
应用程序/用户SQL操作
基于 SQL 标准扩展的统一查询语言解析
数据表模式解析
逻辑算子拆分与映射
查询优化
基于代价模型的异构数据查询计划生成
查询计划缓存/冗余查询优化过程消除
基于物化视图的查询中间结果重用
查询执行
跨引擎执行框架
查询处理的运行时加速机制
执行状态监测模块
体系结构支撑
云原生的解耦合架构
服务层
资源监测
弹性伸缩
元数据维护
计算层
存储层
分布式共享缓存
多类型数据分区
基于热点数据识别的智能数据分布
单节点数据处理架构
基于 DAG 表示的并行流水线化数据处理
分布式并行查询计算框架
多计算节点
任务划分与调度
分布式系统容灾策略

提纲

01	02	03	04	05
研究背景	研究目标	关键技术	总结展望	团队介绍

项目资助

- “中日韩前瞻计划” （Asia3 Foresight Program）
  - ✓国家自然科学基金委员会（NSFC）
  - ✓日本学术振兴会（JSPS）
  - ✓韩国国家研究基金会（KNRF）
  - ✓共同发起设立的合作研究项目。旨在资助中日韩三国科学家在选定领域开展合作研究，共同培养杰出科技人才和解决区域性科学问题，促进提升亚洲地区的科研水平与世界影响力。
- 2024年度
  - ✓资助领域为“**新一代数据库和数据赋能技术“(F02)，2024年8月1日至2029年7月31日。**

合作进展

- 3月6日下午，华师大、东大和人大数据库团队访问了东京大学喜连川优教授团队。围绕A3前瞻计划项目，共同探讨了实施路径、国际合作模式、前沿技术突破、跨区域协调等问题

展望

金融、科技、教育、物流等领域应用

统一编程语言

统一、通用的**数据模型**

基于**云原生**的体系结构

跨**域**、跨**引擎**、跨**模态**的联合分析优化

数据模型

挑战：支持多源异构数据的统一数据模型

体系结构

挑战：异构计算感知、灵活的数据库体系结构

核心技术

挑战：新型数据库的查询优化和跨域数据管理

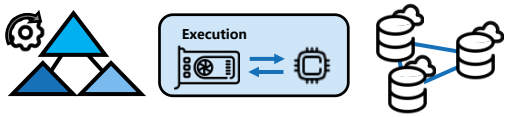

数据大众化、开发大众化、AI 大众化！

致谢

- 国家自然科学基金委员会
- A3前瞻计划项目“新一代数据库和数据赋能技术“
- 项目首席周傲英教授
- 华东师范大学团队
- 中国人民大学团队

提纲

01	02	03	04	05
研究背景	研究目标	关键技术	总结展望	团队介绍

数据与知识工程团队介绍：团队组成

团队负责人

于戈 教授（二级）、CCF会士

方向1：多模态大数据集成与治理

方向2：大数据管理与智能计算

方向3：数据驱动的知识工程

方向负责人

申德荣 教授

张岩峰 教授

谷峪 教授

王大玲 教授

鲍玉斌 教授

张天成 教授

方向骨干

寇月

聂铁铮

副教授

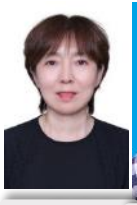

李晓华

巩树凤

副教授

李芳芳

讲师

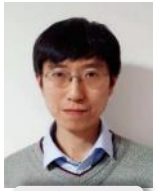

冯时

刘正皓

董晓梅

张一飞

冷芳玲

杨晓翠

副教授

讲师

数据与知识工程团队介绍：研究方向

聚焦多模大数据集成与治理、跨模态大数据管理与分析、新硬件加速的大数据计算、大模型系统训练推理加速、多模态大模型RAG技术、社会媒体与智慧教育大数据应用等关键技术研究、系统开发和人才培养工作，有力支撑国家对于数据科学与知识工程自主可控的战略目标

多模大数据集成与治理

数据处理与整合

数据清洗 异常检测 实体识别 数据集成

数据建模与治理

多模数据统一建模 大数据治理

精确性 完整性

实体同一性

大数据管理与智能计算

新型多模态数据库

跨域数据湖系统

云原生和新硬件数据处理

大模型系统训练推理加速

低延迟 高吞吐 可扩展

数据驱动的知识工程

多模态大模型RAG技术

知识赋能的多智能体

垂直领域知识图谱

基于知识工程的大数据应用

智慧教育 情感分析 对话系统

智能化 个性化 可解释

科研项目情况（近三年代表性项目）

类别	项目名称	经费	负责人	类别	项目名称	经费	负责人
重点研发课题	基于非易失内存的数据库存储系统	490万	张岩峰	面上项目	单调图计算的理论与系统	66万	张岩峰
联合基金重点项目	基于大数据的交互式个性化教学环境构建方法研究	675万	于戈	面上项目	面向情感交互的人机对话文本生成技术研究	72万	王大玲
联合基金重点子课题	多中心跨域湖仓融合架构关键技术	122万	谷峪	面上项目	数据驱动与规则驱动双引擎的增强型数据集成技术	70万	申德荣
联合基金重点子课题	面向图学习的分布式原生图存储和计算方法研究	80万	张岩峰	面上项目	基于群组生成机理的可解释群组推荐方法研究	66万	寇月
联合基金重点子课题	基于学习行为时空关联的可解释性建模方法	64万	鲍玉斌	面上项目	基于在线学习交互数据的可解释性学生学习画像技术研究	61万	张天成
国际合作重点子课题	新一代数据库和数据赋能技术	100万	于戈	面上项目	面向大数据融合的区块链数据管理关键技术研究	66万	聂铁铮
重点研发子课题	面向混合负载的智能异构计算技术	60万	谷峪	面上项目	面向情感交互的人机对话文本生成技术研究	64万	冯时
重点研发子课题	高效融合的多模数据处理模型与优化	60万	聂铁铮	面上项目	以用户为中心的情绪诱导对话生成关键技术研究	61万	冯时
国家人才项目	国家高层次人才支持计划-青年拔尖人才	170万	张岩峰	青年基金	支持富文本文档检索的多片段语义表示融合技术	30万	刘正皓
面上项目	跨地理区域联盟区块链系统的高性能事务处理技术	53万	于戈	青年基金	支持Serverless架构的高可伸缩性云原生图处理技术	30万	巩树凤
面上项目	支撑大规模图神经网络的分布式数据处理技术	67万	谷峪	大型企业合作	华为数据库扩展性研究技术合作项目	320万	张岩峰

近三年在研重点研发课题1项，子课题2项；基金重点项目1项，子课题3项，国际合作课题1项；国家级人才项目1项；面上项目10项；青年基金2项；主要军工项目2项；企事业合作项目10余项

学术论文情况（近三年）

CCF A会议	CCF A期刊	CCF B期刊、会议	中文一级学报
40	12	28	9

SIGMOD	VLDB	ICDE	ACL	AAAI	SIGIR	WebConf	TKDE	TPDS	VLDBJ	TOIS
6	11	8	10	2	2	1	6	4	1	1

代表性成果应用和转化（近三年）

- 研发的无协调数据库算法，集成到华为国产数据库**GaussDB**中，**提升了跨域数据处理能力，获首届CCF优秀产学案例**

HUAWEI

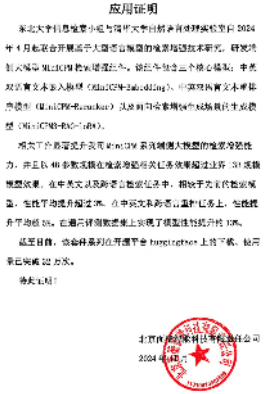
应用证明

- 研发的动态图计算算法，集成到阿里国产图计算平台**GraphScope**，**提升了国产图计算平台的实时处理能力**

Alibaba Group

- 研发的检索增强组件，应用至面壁端侧大模型**MiniCPM**中，**累计下载量超过32万次，发布时在MTEB 的榜单上中文排名第一，性能显著超过13B模型**

面壁智能

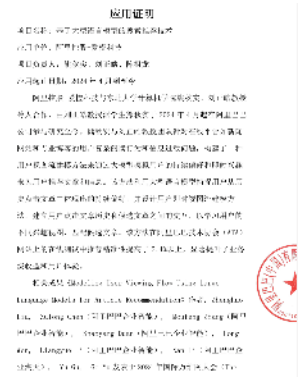
应用证明

- 研发的文章和信息推荐模型SINGLE，应用至**阿里巴巴爱橙科技**中，在线测试证明推荐**精准性提高了3%，提升了业务级收益和用户体验**

Alibaba Group

奖励情况（近三年）

年份	奖励类别	奖励名称	完成人
2023年	中国计算机学会自然科学二等奖	云环境下大规模图迭代计算的理论与系统	于戈、张岩峰、谷峪、巩树凤等
2022年	中国电子学会科技进步一等奖	多源异构数据湖管理系统及应用	于戈（第二完成人）

2023年CCF科技成果奖
自然科学二等奖
授予
东北大学
"云环境下大规模图迭代计算的理论与系统"项目
主要完成人 于戈、张岩峰、谷峪、王志刚、巩树凤、王千阁

年份	人才类别	完成人
2022年	国家“万人计划”青年拔尖人才	张岩峰
2025年	中国科协青年人才托举工程	刘正皓
2024年	辽宁省杰出青年基金	张岩峰

中国科学技术协会
青年人才托举工程
入选证书
刘正皓
NO.YES202401.69

谢谢！